Compilation

II. Analyse lexicale

Jacques Farré

Jacques.Farre@unice.fr

http://deptinfo.unice.fr/~jf/Compil-L3/

Introduction

- cette partie du cours a pour pré-requis le cours *Automates et langages* du premier semestre
  - on suppose connues les notions de langage régulier, d'expression régulière, d'automate fini
- on se concentrera sur les problèmes pratiques de l'analyse lexicale et l'utilisation de générateurs d'analyseurs (*Flex*, *JavaCC*)
  - extensions nécessaires aux expressions régulières pour traiter des cas réels
  - reconnaissance avec lecture en avant, reconnaissance contextuelle
  - réduction de l'automate produit par les expressions régulières
  - écriture « à la main » de l'analyseur lexical
  - relation avec l'analyseur syntaxique
- vocabulaire : par la suite, on employera indifféremment les termes *lexème*, *terminal* ou *token*

Utilité d'avoir un analyseur lexical

- le texte source comprend du ≪ bruit ≫ comme les espaces, les fins de ligne, les commentaires . . . qui souvent ne sont pas grammaticalement pertinents (et qu'il est même quasiment impossible d'inclure dans la grammaire)
- certaines formes sources sont grammaticalement équivalentes (les différents identificateurs, les nombres littéraux . . .), ou correspondent à un même symbole pour la grammaire ($\neq$, `!=`)
- l'analyse lexicale a pour rôle de traiter ces problèmes et donc de simplifier l'écriture de l'analyseur syntaxique

Analyseur lexical et analyseur syntaxique

- l'analyse lexicale *produit* des lexèmes, en général au vol à la demande de l'analyseur syntaxique, qui les *consomme*
  - donc l'analyseur demande le prochain lexème à l'analyseur lexical, qui le reconnaît et renvoie un *code* identifiant ce lexème (ou cette classe de lexèmes : identificateurs, nombres ...)
- on pourrait imaginer que l'analyse lexicale travaille indépendamment et fournisse une suite de lexèmes
  - mais on n'a pas besoin, en général, d'avoir reconnu tous les lexèmes pour faire l'analyse syntaxique : la connaissance du lexème courant suffit pour la plupart des méthodes utilisées
  - et malheureusement, pour certains langages (C notamment), la reconnaissance d'un lexème dépend du contexte grammatical dans lequel il se trouve
- les lexèmes sont en général décrits par des expressions régulières

Expressions régulières en *Flex*

un aperçu de la notation (voir le manuel pour plus de notations)

- `a` : la lettre a
- `"."` ou `\.` : le point (`"` et `\` utilisés pour dénoter un caractère spécial)
- `[aeiou]` : une des voyelles (`[...]` dénote **un** caractère parmi un **ensemble**)
- `[0-9]` : un des caractères dont le code ASCII est entre celui de 0 et celui de 9, donc ici un chiffre
- `[^aeiou]` : tout caractère qui n'est pas une voyelle
- `.` : tout caractère sauf la fin de ligne (comme `[^\n]`)
- `abc|xyz` : `abc` ou `xyz`
- `a(bc|xy)z` : `abcz` ou `axyz`
- `ab*c` : `ab...bc`, `b` 0, 1 ou plusieurs fois
- `\**` ou `"*"*` : l'étoile 0, 1 ou plusieurs fois
- `a(bc)+` : `abc...bc`, `bc` 1 ou plusieurs fois
- `a(bc)?d` : `ad` ou `abcd` (c'est à dire `bc` 0 ou 1 fois)

Langage lexical - I

- comme vu précédemment, l'analyseur lexical est chargé de reconnaître les lexèmes du texte source
- chacun de ces lexèmes est un langage
  - dans la plupart des cas, c'est un langage régulier, par exemple

    `[A-Za-z][A-Za-z0-9]*`

    pour reconnaître des identificateurs du genre `X`, `leCompteur`, `i3`, `R2D2` ...
  - c'est un langage fini pour de nombreux lexèmes : `+`, `==`, **for**
- l'analyseur lexical est donc un (souvent gros) automate fini déterministe qui reconnaît l'union des langages des lexèmes
  - un état terminal de cet automate correspond à la reconnaissance d'un mot d'un des langages des lexèmes

Langage lexical - II

Fragment d'automate lexical

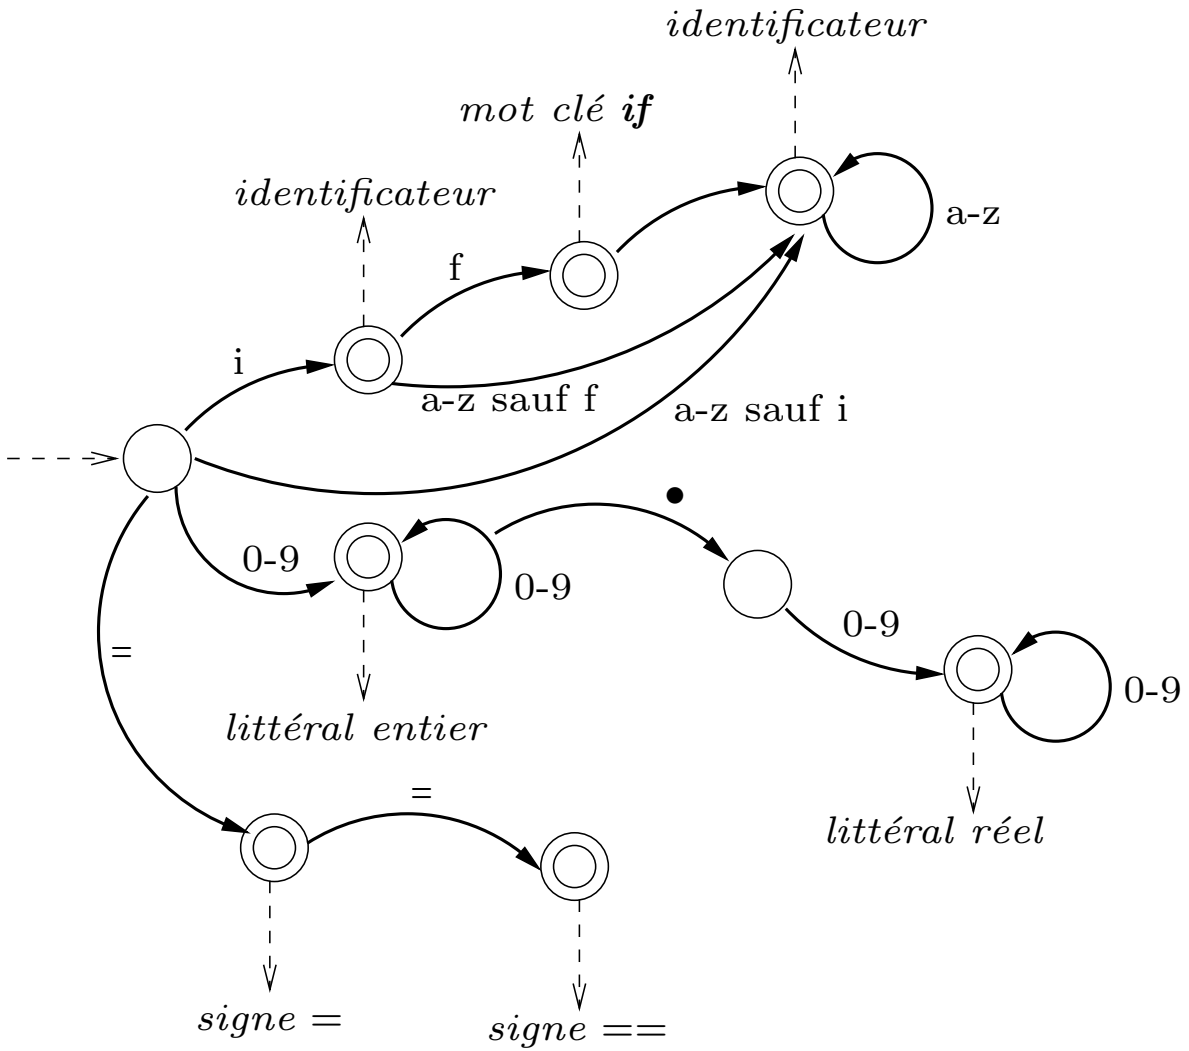

Langage lexical - III

- l'analyseur lexical n'est en général pas tout à fait un automate déterministe
- certains des langages des lexèmes sont préfixes d'un autre : par exemple +, +=, ++, ou encore mots-clés et identificateurs (`for` et `forme`), entiers et réels (3 et `3.14`)
  - le principe est de reconnaître le mot le plus long
  - un état terminal n'implique donc pas toujours l'arrêt de l'automate : il peut continuer, et éventuellement revenir en arrière au dernier état final rencontré
  - et si un mot appartient à 2 langages ?
    - puisqu'un identificateur est en général une suite de lettres, `for` est aussi un identificateur
    - il faut définir une règle pour choisir : par exemple en *flex*, c'est la première définition qui compte

Forme générale d'une description en *Flex*

- comprend 3 parties :
  - déclarations *C* et d'expressions régulière (optionnel),
  - expressions régulières et actions associées en *C*
  - code *C* (optionnel)
- principe de fonctionnement : lit le texte d'entrée, reconnaît un mot d'un des langages, et recommence ; par exemple

```
%{
int nbMots = 0, nbNombres = 0;
%}
L [A-Za-z]
C [0-9]
%%
{L}+   ++nbMots;
{C}+   ++nbNombres
.|\n   ; /* ne rien faire */
%%
int yywrap() { /* appelée quand la fin de fichier est atteinte */
  print ("%d mots et %d nombres\n", nbMots, nbNombres);
  return 0;
}
```

Fragment de description d'un analyseur lexical

- fragment d'analyseur lexical en *flex* :
  (on suppose que l'analyseur syntaxique définit ses lexèmes (des entiers !)
  par des constantes comme `#define IDENT 257` ou `#define FOR 261`)

```
[ \t]                    { /* sauter les espaces */ }
for                      { /* le mot-cle for */
                           return FOR; }
[A-Za-z][A-Za-z0-9]*     { /* c'est un ident */
                           return IDENT; }
[0-9]+                   { /* litteral entier */
                           return ENTIER; }
"+="                     { /* symbole composé */
                           return PLUS_EGAL;
\+                       { /* symbole simple */
                           return '+'; }
```

- si la définition du mot-clé `"for"` avait été écrite **après** celle des identificateurs, il aurait été reconnu comme identificateur et pas comme mot-clé

Langage lexical non régulier

- il peut exister des (rares) constructions lexicales qui sont des langages algébriques (c'est-à-dire non contextuels)
  - par exemple un langage qui accepterait des commentaires emboîtés : `/* aaa /* bbb */ ccc */`
  - il est inutile de mettre en œuvre un automate à pile pour reconnaître ce genre de construction, souvent assez simple
  - une fonction qui lit le texte jusqu'à la fin du commentaire fera l'affaire ; par exemple en *flex* pour reproduire un texte, mais sans les commentaires

```
%{
void skip_comm();
%}

%%
"/*"        { skip_comm(); }
.|\n        { ECHO; } /* on affiche ce qui est lu sinon */ }
```

Langage lexical non régulier

fonction de reconnaissance des commentaires emboîtés

```
void skip_comm() {
  /* fonction (simpliste) sautant les commentaires EMBOÎTÉS */
  int niveau = 1;  /* niveau d'emboitement du commentaire */
  for (;;) {
    /* input est une macro de flex qui lit le prochain caractère */
    int c = input();
    if (c == '*') {
      if (input() == '/')
        if (--niveau == 0) break;
    }
    else if (c == '/')
      if (input() == '*') ++niveau;
    }
  }
}
```

Il faudrait traiter le cas où l'on rencontre la fin de fichier

Langage lexical non régulier

reconnaissance conditionnelle et commentaires emboîtés

- on peut aussi, en *flex*, utiliser des *start conditions*

```
%{
int niveau = 0;
%}
%s COMM      /* declaration d'une condition    */
             /* (celle par defaut s'appelle INITIAL) */
%%
"/*"         { if (niveau == 0) BEGIN(COMM); niveau++; }
               /* reconnu dans toutes les conditions */
<COMM>"*/"   { niveau--; if (niveau == 0) BEGIN(INITIAL); }
<COMM>.|\n   { } /* on n'affiche rien si dans un commentaire */
.|\n         { ECHO; } /* on affiche ce qui est lu sinon */ }
```

- on peut déclarer des conditions exclusives (%x)

Reconnaissance contextuelle

- il existe des langages où une forme lexicale peut correspondre à différents lexèmes selon le contexte
  - selon le contexte gauche : par exemple, **if** reconnu comme mot-clé uniquement s'il est au début d'une instruction ; une *start condition* pourra être utilisée :

    ```
    <DEBINST>if   { /* traitement comme mot-clé */ }
    [a-z]+        { /* traitement avec les identificateurs */ }
    ```

    c'est probablement l'analyseur syntaxique qui demandera à l'analyseur lexical de changer de condition
  - selon le contexte droit : par exemple **if** reconnu comme mot-clé uniquement s'il est suivi d'une parenthèse ; un *trailing context* pourra être utilisé (e_1/e_2 ne reconnaît e_1 que si elle suivie de e_2) :

    ```
    if/[ \t\n]*"(" { /* traitement comme mot-cle si suivi de ( */
    [a-z]+         { /* traitement avec les identificateurs */ }
    ```

  - les 2 peuvent être combinés
  - voir le manuel de *flex* pour la reconnaissance selon la position (début de ligne, fin de ligne . . .)

Problèmes de la reconnaissance contextuelle

- on les rencontre dans des langages mal définis, et pour les langages de programmation, dans des langages anciens (Fortran, PL/1, partiellement C ...)
- ils ne peuvent en général pas être résolus par le seul analyseur lexical : les contextes sont le plus souvent des langages non-contextuels (!), reconnus par l'analyseur syntaxique
- donc forte interaction entre les 2 analyseurs, au mépris de la lisibilité, de la fiabilité et des facilités de maintenance et d'extension
- c'est pourquoi les langages modernes de programmation évitent ces questions de reconnaissance contextuelle, mais malheureusement pas les langages de script, de description ... conçus la plupart du temps par des non spécialistes des langages

Exemple de problème de la reconnaissance contextuelle

Le fameux bogue d'une mission Mercury !

- en *Fortran*, espaces non significatifs, et déclaration implicite des identificateurs débutant par `i, j ... n` comme variables entières, les autres comme variables réelles
  - par conséquent `DO12I=1.25` est interprété comme *identificateur `DO12I`, opérateur d'affectation =, réel `1.25`*
  - mais `DO12I=1,25` est interprété comme *mot-clé `DO`, etiquette `12`, variable `I`* : boucle qui se termine à l'énoncé étiqueté `12` pour `i` allant de 1 à 25
  - d'après la légende, on aurait perdu une fusée du projet Mercury à cause d'un '.' à la place de la ',' (à moins que ce ne soit l'inverse)...
- dans la plupart des langages de programmation actuels, les espaces sont significatifs, et les mots-clés sont *réservés*
  - les mots-clés ayant la syntaxe lexicale des identificateurs, l'inconvénient est que plus rien ne les distingue extérieurement, ce qui n'aide pas à la réparation d'erreurs

Performances de l'analyseur lexical

- en règle générale, l'analyseur lexical est linéaire en temps sur le nombre de caractères du texte d'entrée
  - même s'il doit parfois reculer, c'est d'un nombre borné de fois (voir l'exemple avec +, +=, ++)
- mais on pourrait imaginer un langage très mal conçu où le temps serait quadratique
  - supposons qu'il n'y ait que 2 lexèmes : `a` et `a...ab` ; sur l'entrée `a...a`, il doit aller, pour reconnaître **chaque** `a` jusqu'à la fin du texte, soit $n-1+n-2+...1 = \mathcal{O}(n^2)$ lectures
- autre facteur de performance, la taille de l'automate : elle peut poser des problèmes de cache mémoire qui ralentissent fortement l'exécution
  - si l'automate est implémenté sous forme de table, il existe des techniques de compression, mais au prix d'un accès plus coûteux aux éléments de la table

Réduction de la taille de l'automate

- la discrimination par l'automate entre les identificateurs et les mots-clés multiplie le nombre d'états

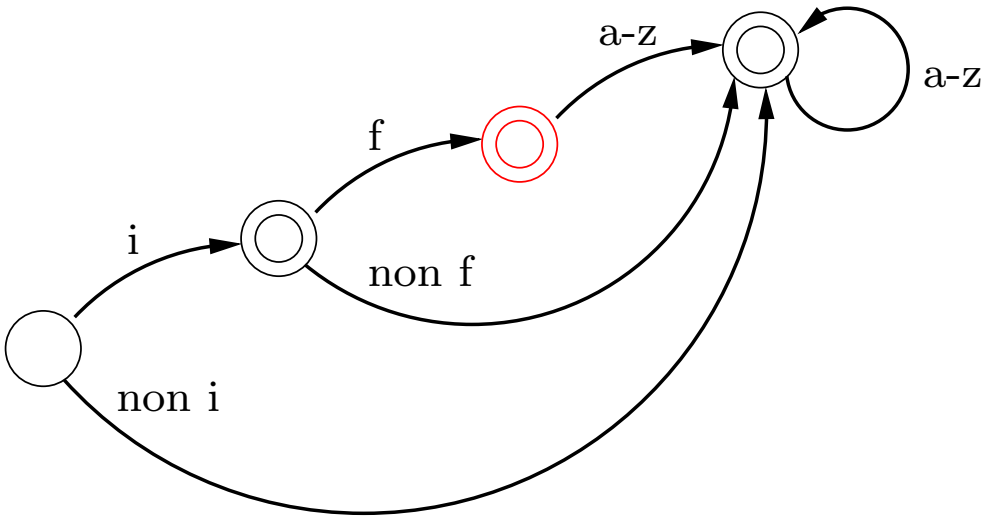

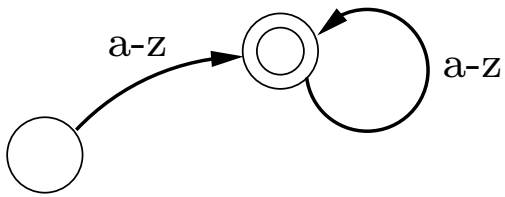

automate de reconnaissance des identificateurs

automate de discrimination entre `if` *et les identificateurs*

- on a donc intérêt à ne faire reconnaître par l'automate que les identicateurs, puis regarder dans une table si l'identificateur reconnu correspond à un mot-clé
  - la recherche dans cette table peut être rapide (par dichotomie, par adressage dispersé . . .)

Faciliter le travail du reste du compilateur

- si l'analyse syntaxique peut traiter les identificateurs sans les distinguer, l'analyse sémantique ou le traitement des erreurs ont besoin de savoir de quel identificateur il s'agit (idem pour les constantes : nombres, chaînes . . .)
- l'analyseur lexical doit donc fournir, en plus de la classe syntaxique du lexème, sa forme source (ou sa valeur pour une constante)
- le texte reconnu est dans la variable `yytext`, et sa longueur dans `yyleng` ; par exemple

```
%{
extern int ival;     /* valeur du lexème si nombre entier */
extern char* ident; /* l'ident proprement dit */
%}
%%
[A-Za-z]+    { ident = strdup (yytext); return IDENT; }
[0-9]+       { ival = atoi (yytext; return ENTIER; }
```

Faciliter le travail du reste du compilateur

tout en garantissant ses performances

- pour éviter de multiplier le nombre de chaînes de caractères identiques transmises aux autres analyseurs, l'analyse lexicale peut garder les identificateurs dans une table, et retourner l'entrée de cette table correspondant à l'identificateur reconnu

  du point de vue performances, c'est la différence entre == et `equals` sur des chaînes (Java), ou entre == et `strcmp` (C)

```
%{
extern char* ident; /* l'ident proprement dit */
char* chercherIdent (char*);
%}
%%
[A-Za-z]+   { ident = chercherIdent (yytext); return IDENT; }
...
%%
/* déclaration de la table des identificateurs
   et définition de chercherIdent */
```

- idem pour les constantes chaînes . . . ,

Traitement des identificateurs et des mots-clés

- spécification d'un module de traitement des identificateurs

```
typedef struct InfoIdent {
  const char* texte; /* le mot-clé ou l'ident proprement dit */
  int code_mot_cle;  /* code du mot-clé, ou code IDENT */
} InfoIdent

InfoIdent table[MAX] = {{"for", FOR}, {"do", DO} ... };
  /* une table de taille dynamique serait mieux */

InfoIdent* chercher (const char* s);
/* Retourne l'entrée de la table correspondant à l'identificateur
   ou au mot-clé qui s'écrit comme s.
   AJOUTE l'identificateur s à la table S'IL N'Y EST PAS DÉJÀ.
   Initialement, la table ne contient que les mots-clés du
   langage (et éventuellement des identificateurs prédéfinis)
*/
```

Exercice : écrire le code de la fonction chercher

Relations analyseur lexical - analyseur syntaxique

- comme vu plus haut, en général, l'analyseur syntaxique demande les lexèmes au fur et à mesure de ses besoins
- l'analyseur lexical renvoie la classe du lexème, et aussi d'autres informations utiles comme
  - numéro de ligne où il a été reconnu, et éventuellement sa position dans la ligne et le nom du fichier
  - des informations sémantiques, comme le lexème lui-même si c'est un ident, sa valeur si c'est un nombre, une chaîne ...
  - par exemple en *C*

```
struct LexInfo {
  int ligne;
  union {                 /* selon que le lexème est : */
    int ival;             /* une constante entière     */
    double rval;          /* une constante réelle      */
    const char* sval; /* un ident ou une chaîne    */
  } val;
} lexInfo;
```

Fragment de description d'un analyseur lexical

offrant des informations utiles au reste du compilateur

- on suppose que l'analyseur syntaxique définit ses lexèmes (des entiers !) par des constantes comme `#define IDENT 257`, `#define FOR 258` ...qui sont aussi les codes utilisés dans la table `InfoIdent`
- fragment d'analyseur lexical en *flex* :

```
[A-Za-z][A-Za-z0-9]*  { /* ident ou mot-clé ? */
                        InfoIdent* i = chercher(yytext);
                        lexInfo.ligne = yylineno;
                        if (i->code == IDENT)
                          lexInfo.sval = i->texte;
                        return i->code; }

[0-9]+                { /* c'est un littéral entier */
                        lexInfo.ligne = yylineno;
                        lexInfo.ival = atoi(yytext);
                        return ENTIER; }
```

Analyse lexicale avec *JavaCC*

`https://javacc.dev.java.net/`

- *JavaCC* (*Java* Compiler Compiler) est (notamment) un générateur d'analyseur lexical et syntaxique produisant du *Java*
  - notation (presque) uniforme pour les aspects lexicaux et les aspects syntaxiques : les expressions régulières
  - *JavaCC* (initialement *Jack*) est inspiré de *PCCTS*, qui a lui-même donné *ANTLR* (`http://www.antlr.org/`)
- un fichier de description pour *JavaCC* est, par convention, suffixé par `.jj`
- *JavaCC* est appelé par la commande :

  ```
  javacc options fichier.jj
  ```
- le résultat est un ensemble de classes *Java*

Structure d'un fichier *JavaCC*

- le fichier doit avoir la structure suivante :

```
options /* partie optionnelle */
PARSER_BEGIN ( nom de l'analyseur )
  une classe java /* avec une méthode main */
PARSER_END ( nom de l'analyseur )
règles lexico-syntaxiques
```

- par exemple

```
options {
  IGNORE_CASE=true;
}

PARSER_BEGIN(Exemple)
  public class Exemple { ... }
PARSER_END(Exemple)
... // règles de grammaire
```

- le fichier à faire compiler par *Java* sera `Exemple.java`

L'analyseur *JavaCC*

- il est lancé par la méthode `main` de la classe *Java*
- par exemple, si on veut juste regarder les lexèmes lus sur l'entrée standard

```
public class Exemple {
  public static void main(String args[]) {
    Exemple parser = new Exemple(System.in);
    Token tok = parser.getNextToken();
    while (tok.kind != EOF) {
      System.out.println (token.image);
      tok = parser.getNextToken();
    }
  }
}
```

- la classe est une classe *Java* à part entière, qui peut avoir des attributs, des méthodes ...
  - *JavaCC* s'empresse de lui en ajouter, regardez le code *Java* de la classe produite

Règles lexicales en *JavaCC*

Définition des lexèmes

- les lexèmes sont décrits par des expressions régulières
  - les symboles du vocabulaire sont toujours entre "
  - les opérateurs sont analogue à ceux de *Flex*
  - les expressions régulières peuvent être nommées
    un nom précédé de # est une ER auxillaire qui participe à la définition d'un lexème, mais n'en est pas un
- par exemple :

```
TOKEN : /* ce qu'on reconnait comme lexèmes */
{
    < CONSTANT: ( <DIGIT> )+ >
|   < #DIGIT: ["0" - "9"] >

|   < IDENT: ( <LETTER> )+ >
|   < #LETTER: ["a" - "z"] >
       /* si l'option IGNORE_CASE est vraie, on
          reconnaitra aussi bien abc que ABC ou AbC */
}
```

Règles lexicales en *JavaCC*

Parties du texte à ignorer

- la catégorie la plus courante est `SKIP` : les portions de texte conformes à ces définitions sont ignorées

```
SKIP : { /* on saute les espaces */
       " "
       | "\n"
       | "\t"
       | < "//" (~["\n"])* > /* et les commentaires // */
}
```

- la catégorie `SPECIAL_TOKEN` est aussi ignorée, mais accessible par l'attribut `specialToken` du lexème suivant
  - permet par exemple de raccrocher un commentaire `/** ... */` pour une application comme *JavaDoc*

Écriture à la main de l'analyseur lexical

- l'écriture directe de l'analyseur lexical peut notablement accroître les performances du compilateur
  - travail plus fastidieux que difficile : il s'agit simplement de câbler en dur un automate fini
  - permet aussi des ≪ ruses ≫ que ne peut pas toujours permettre un générateur d'analyseurs
- il faut bien sûr éviter de construire un automate non déterministe, car personne ne viendra le déterminiser (c'est la faiblesse de l'approche)
  - par exemple, ne pas programmer l'automate non déterministe sous-jacent à +|+=, mais celui (déterministe) correspondant à +=? (reconnaissance du +, suivi éventuellement d'un =)

Quelques principes d'écriture manuelle de l'analyseur lexical

- on suppose que `car` est le caractère suivant la portion de texte reconnue, et `carsuiv()` la fonction qui lit le prochain caractère du texte d'entrée
- quelques schémas de codage des expressions régulières
  - a : `if (car == 'a') car = carsuiv(); else erreur();`
  - a e_1 | b e_2 :

```
if (car == 'a') {
  car = carsuiv(); ... // + code pour analyser e1
} else if (car == 'b') {
  car = carsuiv(); ... // + code pour analyser e2
} else erreur();!
```

  - a (b e_1)* :

```
if (car == 'a') {
  car = carsuiv();
  while (car == 'b') { car = carsuiv();
                       ... } // + code pour analyser e1
} else erreur();
```

Fragments d'un analyseur lexical manuel

On suppose qu'un tableau `int classe[256]` donne la classe de chaque caractère (par exemple `classe['a']=LETTRE` et `classe['+']='+'`)

```
int lexemeSuivant() {
  InfoIdent* i; int cla;
  for (;;) {
    switch (classe[car]) {
      case ESPACE : car = carsuiv(); break;
      case LETTRE : do { /* ident ou mot-clé ? */
                    /* mémoriser 'car' dans une chaine 'str' */
                    car = carsuiv(); cla = classe[car];
                  } while (cla == LETTRE || cla == CHIFFRE);
                  i = chercher(str); return i->code;
      case '+' : car = carsuiv();
                 if (car == '=') { car = carsuiv(); return PLUSEGAL; }
                 else return '+';
      case "/" : /* distinguer entre le simple / ==> return '/'
                    et le debut de commentaire ==> sauter le
                    commentaire puis break (on revient reconnaître
                    le lexème suivant) */
      ...
```